

大连理工大学本科毕业设计（论文）

基于 WiFi CSI 的脊柱姿态检测方法研究

Research on Spinal Posture Detection Based on WiFi CSI

学 院（系）： 软件学院

专 业： 网络工程

学 生 姓 名： 路琨、文浩然

学 号： 20232241019 20232241392

指 导 教 师： 王雷

评 阅 教 师：

完 成 日 期： July 19, 2026

大连理工大学

Dalian University of Technology

摘 要

脊柱姿态异常与人体长期坐姿、站姿和运动习惯密切相关。传统脊柱姿态检测方法多依赖摄像头、可穿戴设备或专业医学检测设备，在隐私保护、长期佩戴舒适性和日常场景部署成本方面存在一定限制。为实现低侵入、非接触的室内脊柱姿态辅助检测，本文研究一种基于 WiFi 信道状态信息（Channel State Information, CSI）的三分类检测方法。

本文以 WiFi CSI 数据为基础，将脊柱姿态检测建模为正常姿态、脊柱后凸相关姿态和脊柱侧弯相关姿态的分类问题。方法首先解析原始 CSI 文件，获得时间帧、子载波和天线链路维度上的复数信道响应；随后以接收天线相位比构造相对相位特征，并沿时间维度进行相位展开；在此基础上采用长度为 512、步长为 256 的滑动窗口组织时间序列，并对每个原始文件聚合均值、标准差、分位数、相邻帧差分统计量以及相位正余弦统计量，形成 1620 维文件级特征；最后使用 ExtraTrees 集成分类器完成三类脊柱姿态识别。

实验使用 750 个 CSI 原始文件，三类姿态各 250 个样本，按照固定随机种子在文件级划分训练集、验证集和测试集。在 113 个测试文件上，最终模型取得 92.04% 的准确率和 92.08% 的宏平均 F1 值。实验结果表明，基于相位比统计特征和 ExtraTrees 分类器的 WiFi CSI 脊柱姿态检测方法能够有效区分三类姿态，为室内非接触式脊柱健康辅助检测提供了一种可行方案。

关键词：WiFi CSI；脊柱姿态检测；相位比；统计特征；ExtraTrees

Research on Spinal Posture Detection Based on WiFi CSI

Abstract

Spinal posture abnormalities are closely related to long-term sitting, standing and movement habits. Conventional spinal posture detection methods usually rely on cameras, wearable sensors or professional medical devices, which may introduce limitations in privacy protection, wearing comfort and deployment cost in daily indoor scenarios. To support low-intrusive and contactless spinal posture assessment, this thesis studies a three-class detection method based on WiFi Channel State Information (CSI).

The proposed method formulates spinal posture detection as a classification task among normal posture, kyphosis-related posture and scoliosis-related posture. Raw CSI files are first parsed into complex channel responses over time frames, subcarriers and antenna links. Then relative phase features are constructed by calculating receive-antenna phase ratios, followed by temporal phase unwrapping. A sliding window with length 512 and step 256 is used to organize the CSI sequence. For each original file, statistical features including mean, standard deviation, quantiles, adjacent-frame difference statistics, and sine/cosine phase statistics are aggregated into a 1620-dimensional file-level feature vector. Finally, an ExtraTrees ensemble classifier is used for three-class spinal posture recognition.

The experiment uses 750 CSI files, with 250 samples for each posture category. The dataset is split into training, validation and test sets at the file level using a fixed random seed. On 113 test files, the final model achieves 92.04% accuracy and 92.08% macro F1 score. The results show that the WiFi CSI spinal posture detection method based on phase-ratio statistical features and ExtraTrees classification can effectively distinguish the three posture categories and provides a feasible solution for contactless indoor spinal health assessment.

Key Words: WiFi CSI; Spinal Posture Detection; Phase Ratio; Statistical Features; Extra-Trees

目 录

摘 要.....	I
Abstract.....	II
引 言.....	1
1 相关研究与技术基础.....	3
1.1 WiFi 人体感知研究.....	3
1.2 CSI 信道状态信息.....	3
1.3 CSI 相位校正.....	3
1.4 传统机器学习分类模型.....	3
1.5 深度学习时间序列模型.....	4
2 CSI 数据表示与特征处理.....	5
2.1 CSI 数据结构.....	5
2.2 幅度与相位特征.....	5
2.3 接收天线相位比特特征.....	5
2.4 滑动窗口组织.....	7
2.5 文件级统计特征.....	7
3 基于相位比特统计特征的脊柱姿态检测方法.....	8
3.1 问题定义.....	8
3.2 方法总体框架.....	8
3.3 文件级特征构建.....	9
3.4 ExtraTrees 分类模型.....	9
3.5 检测结果输出.....	10
4 实验设计与结果分析.....	11
4.1 实验目标.....	11
4.2 数据集与划分方式.....	11
4.3 评价指标.....	12
4.4 模型对比实验.....	13
4.5 最终测试结果.....	14
4.6 结果分析.....	15
5 系统实现与检测流程.....	16
5.1 系统模块划分.....	16
5.2 系统功能设计.....	16

5.3 训练流程	16
5.4 检测流程	17
5.5 复现性验证	17
5.6 应用特点	17
结 论	18
参 考 文 献	19

引 言

脊柱健康与人体长期姿态、运动习惯和日常生活方式密切相关。脊柱后凸、脊柱侧弯等姿态异常在早期往往表现为身体形态和运动姿态的细微差异，若能够通过低成本、非接触的方式进行持续感知，可为日常健康监测和早期辅助筛查提供技术支持。传统姿态检测方法多依赖摄像头、可穿戴设备或专业医学检测设备。摄像头方案容易受到视角、光照和隐私问题影响；可穿戴设备需要用户主动佩戴，长期使用的舒适性和依从性有限；专业医学设备检测精度高，但部署成本较高，难以覆盖普通室内场景下的连续感知需求。

近年来，基于 WiFi 信号的人体感知技术受到广泛关注。WiFi 设备在室内环境中普遍存在，无线信号在传播过程中会受到人体反射、遮挡、散射和多径效应影响。信道状态信息（Channel State Information, CSI）能够描述不同子载波和天线链路上的细粒度信道响应。相较于接收信号强度（Received Signal Strength Indicator, RSSI），CSI 同时包含幅度和相位信息，能够更细致地反映人体姿态对无线信道的扰动。因此，利用 CSI 进行非接触式人体姿态检测具有较好的研究价值和应用潜力。

本文面向脊柱姿态检测任务，研究一种基于 WiFi CSI 的三分类识别方法。该方法将检测目标划分为正常姿态、脊柱后凸相关姿态和脊柱侧弯相关姿态。系统首先解析原始 CSI 文件，获得时间帧、子载波、接收天线和发射天线维度上的复数信道响应；随后构造接收天线相位比特征，并沿时间维度进行相位展开；在此基础上通过滑动窗口组织 CSI 序列，再将每个原始文件的窗口特征聚合为文件级统计特征；最后使用 ExtraTrees 集成分类器完成姿态类别预测。

本文的主要工作包括以下几个方面：

- （1）分析 WiFi CSI 用于脊柱姿态检测的可行性，说明人体姿态变化与无线信道幅度、相位扰动之间的关系。
- （2）构建基于接收天线相位比的 CSI 特征处理方法，削弱硬件相位偏移和公共相位误差对分类特征的影响。
- （3）设计文件级统计特征聚合流程，将连续 CSI 相位比序列转换为固定长度特征向量，便于传统机器学习模型进行分类。
- （4）采用 ExtraTrees 集成分类器建立三类脊柱姿态检测模型，并与 TCN、SVM 和 Random Forest 等方案进行比较。
- （5）在文件级留出测试集上进行实验验证，分析准确率、精确率、召回率、F1 值和混淆矩阵结果。

全文结构安排如下：第一章介绍相关研究与技术基础；第二章说明 CSI 数据表示与

特征处理方法；第三章给出基于相位比统计特征和 ExtraTrees 的脊柱姿态检测方法；第四章介绍实验设计、模型对比和测试结果；第五章阐述系统实现与检测流程；最后对全文工作进行总结。

1 相关研究与技术基础

1.1 WiFi 人体感知研究

WiFi 人体感知利用无线信号与人体之间的相互作用进行行为、姿态和身份识别。人体进入无线传播区域后，会改变信号传播路径，使接收端观测到的信道响应发生变化。已有研究表明，CSI 能够刻画子载波级别的信道变化，在室内定位、动作识别和手势识别等任务中具有较好的表现^[1-3]。

与基于图像的姿态检测方法相比，WiFi 感知不直接采集人体图像，具有更好的隐私保护特性；与可穿戴设备相比，WiFi 感知不需要用户佩戴额外传感器，适合室内无感化部署。因此，将 WiFi CSI 引入脊柱姿态检测任务，有助于构建低成本、非接触的姿态感知方法。

1.2 CSI 信道状态信息

CSI 描述无线信号在发射端与接收端之间传播时的信道响应。对于正交频分复用系统，不同子载波上的 CSI 能够反映不同频率分量受到的衰落、反射和多径影响。CSI 通常以复数形式表示，其中幅度反映信号强弱，相位反映信号传播过程中的相对偏移。

人体姿态变化会引起信号传播路径变化，使 CSI 序列在时间维度上呈现出不同模式。脊柱姿态相关的身体形态变化主要体现在躯干轮廓和运动方式差异上，这些差异会改变人体对无线信号的遮挡和反射方式，从而形成可被模型学习的 CSI 特征。

1.3 CSI 相位校正

CSI 原始相位通常受到采样时钟偏移、载波频率偏移、硬件延迟和环境噪声影响。若直接使用原始相位进行分类，模型容易受到设备状态和环境变化干扰。相位校正的目标是削弱与人体姿态无关的公共相位误差，增强由人体姿态变化引起的相对相位差异。

基于 CSI 比值的相位校正方法通过不同天线链路之间的复数比值构造相对相位特征。本文采用接收天线之间的相位比作为主要特征：以一根接收天线为参考，将其他接收天线的复数 CSI 与参考天线 CSI 相除，再取复数比值的幅角作为相位比。该方法保留链路之间的相对变化信息，并在一定程度上抵消共同相位偏移，适合用于多天线 WiFi 感知任务。

1.4 传统机器学习分类模型

CSI 姿态检测任务中的样本数量通常有限，而单个样本可以从多天线、多子载波和时间维度构造出较高维度的特征。对于此类小样本、高维、非线性分类问题，传统机器

学习模型仍具有较强适用性。支持向量机（Support Vector Machine, SVM）能够通过核函数处理非线性分类边界^[4]；Random Forest 通过集成多棵决策树降低单棵树的方差^[5]；ExtraTrees 在随机森林基础上进一步增强特征选择和切分阈值的随机性，从而构造差异更大的树模型并提升集成泛化能力^[6]。

本文最终采用 ExtraTrees 作为脊柱姿态检测分类器。该模型能够处理高维统计特征，不依赖严格的特征缩放过程，并能通过多棵随机树的集成投票表达复杂的非线性特征组合。对于当前 750 个 CSI 文件构成的数据集，ExtraTrees 在测试集上取得了较好的分类表现。

1.5 深度学习时间序列模型

深度学习模型能够从原始或半结构化特征中自动学习分类表示。对于 CSI 姿态检测任务，输入数据具有明显的时间序列属性，因此可使用一维卷积网络、循环神经网络或时间卷积网络进行建模。时间卷积网络（Temporal Convolutional Network, TCN）通过卷积核在时间维度上滑动提取局部动态特征，并通过多层结构扩大感受野^[7]。

本文实验过程中曾使用 TCN 作为窗口级时间序列分类基线。实验结果显示，在当前数据规模下，TCN 容易学习到受试者和采集环境中的局部细节，而测试集表现低于基于文件级统计特征的树集成模型。因此，本文将 TCN 作为模型对比的一部分，并将相位比统计特征与 ExtraTrees 分类器确定为最终方案。

2 CSI 数据表示与特征处理

2.1 CSI 数据结构

WiFi CSI 数据记录了无线信道在时间、频率和空间链路的变化。对于包含多根发射天线和接收天线的采集设备，CSI 可表示为一个多维复数矩阵。矩阵中的每个元素对应某一时刻、某一子载波和某一发射接收天线链路上的信道响应。

设 CSI 序列包含 T 个时间帧、 S 个子载波、 R 根接收天线和 M 根发射天线，则 CSI 数据可表示为

$$X_{\text{csi}} \in \mathbb{C}^{T \times S \times R \times M}. \quad (2.1)$$

其中，时间维度反映人体姿态变化过程中的连续扰动；子载波维度反映不同频率分量下的信道差异；接收天线和发射天线维度反映不同空间传播链路上的信号变化。

2.2 幅度与相位特征

CSI 是复数形式，其幅度和相位分别表示为

$$H = Ae^{j\phi}, \quad (2.2)$$

其中 A 为幅度， ϕ 为相位。幅度描述接收信号能量变化，相位描述信号传播过程中的相对偏移。人体姿态不同会造成信号传播路径和多径叠加方式不同，因此幅度和相位均包含姿态相关信息。

在实际采集中，幅度特征通常较为稳定，但容易受到距离、遮挡和发射功率变化影响；相位特征对细微路径变化更加敏感，但同时也更容易受到硬件偏移和噪声影响。因此，本文重点采用相位校正后的相对相位特征作为脊柱姿态检测的重要输入。

2.3 接收天线相位比特征

相位比特征通过不同接收天线之间的 CSI 复数比值构造。设 $H_{t,s,r,m}$ 表示第 t 个时间帧、第 s 个子载波、第 r 根接收天线和第 m 根发射天线对应的 CSI。本文以第 0 根接收天线为参考，对其他接收天线计算复数比值：

$$R_{t,s,r,m} = \frac{H_{t,s,r,m}}{H_{t,s,0,m} + \varepsilon}, \quad r = 1, \dots, R-1, \quad (2.3)$$

其中 ε 为防止分母为零的极小常数。相位比由复数比值的幅角得到：

$$\theta_{t,s,r,m} = \arg(R_{t,s,r,m}). \quad (2.4)$$

该比值保留了不同接收天线链路之间的相对变化关系，并削弱了一部分公共相位偏移。随后沿时间维度对相位序列进行展开：

$$\tilde{\theta}_{t,s,r,m} = \text{unwrap}(\theta_{t,s,r,m}). \quad (2.5)$$

经过相位展开后，相邻时间帧之间由相位周期性造成的跳变被平滑处理，特征序列能够更稳定地表达人体姿态引起的无线信道变化。

图 2.1 给出了数据集中一个正常姿态文件的实际 CSI 片段。幅度热图展示了 30 个子载波随时间的共同变化；相位比曲线则说明原始角度受 $[-\pi, \pi)$ 周期限制会出现跳变，沿时间维度展开后可获得连续轨迹，为后续差分与分位数统计提供稳定输入。




图 2.1 真实 CSI 样例及接收天线相位比的时间展开效果

2.4 滑动窗口组织

原始 CSI 文件通常包含连续采集得到的一整段时间序列，不同文件的长度可能存在差异。为了统一处理长序列，本文采用长度为 512、步长为 256 的滑动窗口切分相位比序列。设窗口长度为 L 、滑动步长为 P ，则第 k 个窗口可表示为

$$W_k = [\tilde{\theta}_{kP}, \tilde{\theta}_{kP+1}, \dots, \tilde{\theta}_{kP+L-1}]. \quad (2.6)$$

窗口化的作用是将长 CSI 文件分解为若干局部时间片段，使后续特征统计能够同时覆盖局部变化和整段采集过程。本文最终分类单位仍为完整原始文件，而不是单个窗口。这样能够避免仅凭短时间片段判断整体脊柱姿态，同时保留同一文件内多个窗口所包含的时间变化信息。

2.5 文件级统计特征

在完成窗口化后，系统将同一原始文件产生的全部窗口重新聚合，并对每个相位比特特征计算统计量。当前每一时间帧整理得到 180 个相位比特特征；对每个特征计算 9 组统计量，包括均值、标准差、10% 分位数、中位数、90% 分位数、相邻帧差分绝对值均值、相邻帧差分标准差、相位正弦均值和相位余弦均值。因此，每个原始文件最终形成

$$180 \times 9 = 1620 \quad (2.7)$$

维文件级特征向量。

这些统计量分别描述相位比序列的整体水平、波动程度、分布位置、动态变化和周期性信息。分位数统计可降低少量异常帧对特征的影响；差分统计刻画姿态相关扰动在时间上的变化强度；正弦和余弦统计保留相位特征的周期性质。通过文件级聚合，系统将连续 CSI 信号转化为固定长度向量，为 ExtraTrees 分类器提供稳定输入。

3 基于相位比统计特征的脊柱姿态检测方法

3.1 问题定义

本文将脊柱姿态检测建模为基于 WiFi CSI 的文件级三分类问题。设一个原始 CSI 文件为 X ，其对应的姿态标签集合为

$$\mathcal{Y} = \{y_1, y_2, y_3\}, \quad (3.1)$$

其中 y_1 、 y_2 和 y_3 分别表示正常姿态、脊柱后凸相关姿态和脊柱侧弯相关姿态。模型的目标是从 CSI 文件中提取能够反映人体姿态差异的特征，并学习特征向量到姿态类别之间的映射关系：

$$\hat{y} = f(X), \quad \hat{y} \in \mathcal{Y}. \quad (3.2)$$

在无线感知场景中，人体位于发射端与接收端之间时，会对无线信号产生反射、遮挡、散射和多径传播等影响。不同脊柱姿态会改变人体躯干形态及其对无线传播路径的扰动方式，从而使 CSI 的相位比序列呈现出可区分的统计特征。本文利用这一特性进行非接触式脊柱姿态检测。

3.2 方法总体框架

本文方法由 CSI 数据解析、接收天线相位比计算、相位展开、滑动窗口组织、文件级统计特征聚合、ExtraTrees 分类和检测结果输出组成。整体流程可表示为

$$X_{\text{raw}} \rightarrow X_{\text{csi}} \rightarrow X_{\text{ratio}} \rightarrow X_{\text{stat}} \rightarrow g(X_{\text{stat}}) \rightarrow \hat{y}, \quad (3.3)$$

其中 X_{raw} 表示原始采集文件， X_{csi} 表示解析后的复数 CSI 数据， X_{ratio} 表示相位比序列， X_{stat} 表示文件级统计特征， $g(\cdot)$ 表示 ExtraTrees 分类器， $\hat{y}$ 表示最终输出的脊柱姿态类别。

系统首先从原始 .dat 文件中解析复数 CSI，获得时间帧、子载波、接收天线和发射天线维度上的信道响应；然后以第 0 根接收天线为参考，计算其他接收天线与参考天线之间的复数比值，并取幅角得到相位比；随后沿时间维度进行相位展开，减少相位周期跳变带来的不连续；最后将整个文件聚合为 1620 维统计特征，并输入 ExtraTrees 分类器进行三分类预测。

3.3 文件级特征构建

本文不直接将单个窗口作为最终分类对象，而是将一个原始 CSI 文件作为一次检测样本。这样做的原因是，脊柱姿态属于相对稳定的身体状态，单个短窗口可能只包含局部扰动，而完整文件能够更充分地保留一段采集过程中的整体统计规律。

对每个原始文件，系统首先生成长度为 512、步长为 256 的滑动窗口。每个窗口继承其所属文件的姿态标签，但窗口仅用于组织和统计特征，不作为最终投票单位。随后，系统汇总该文件全部窗口中的相位比序列，并对每一维相位比特征计算以下统计量：

- (1) 均值，用于描述相位比的整体水平；
- (2) 标准差，用于描述相位比的波动程度；
- (3) 10% 分位数、中位数和 90% 分位数，用于描述相位比分布；
- (4) 相邻帧差分绝对值均值，用于描述时间变化强度；
- (5) 相邻帧差分标准差，用于描述变化过程的稳定性；
- (6) 相位正弦均值和余弦均值，用于保留相位的周期性信息。

由于每一时间帧具有 180 个相位比特征，每个特征对应 9 个统计量，因此每个 CSI 文件被表示为 1620 维文件级特征向量。该向量既包含整段采集数据的总体分布，也包含局部时间变化信息，能够作为传统机器学习分类器的输入。

3.4 ExtraTrees 分类模型

ExtraTrees 即极端随机树集成模型，是一种由多棵随机决策树组成的监督分类方法。与普通决策树相比，ExtraTrees 在训练每棵树时引入更强的随机性：模型不仅随机选择候选特征，还随机生成候选切分阈值，再从中选择划分效果较好的节点切分方式。多棵树分别给出分类结果后，集成模型通过投票或概率平均输出最终类别。

设文件级统计特征为 $x \in \mathbb{R}^{1620}$ ，第 m 棵树的预测结果为 $h_m(x)$ ，则由 M 棵树组成的 ExtraTrees 分类器可表示为

$$g(x) = \text{mode}\{h_1(x), h_2(x), \dots, h_M(x)\}. \quad (3.4)$$

本文最终模型使用 $M = 700$ 棵极端随机树，并采用类别平衡权重、平方根特征采样和固定随机种子。类别平衡权重用于减小类别样本数量差异带来的影响；平方根特征采样使每棵树在不同特征子空间上学习分类规则；固定随机种子保证实验结果可复现。

ExtraTrees 适合本文任务的主要原因在于：首先，当前数据集文件数量有限，而统计特征维度较高，树集成模型能够在小样本高维特征上获得稳定表现；其次，树模型不依赖严格的特征缩放，对不同量纲的统计特征具有较好兼容性；最后，多棵树的集成能

够表达复杂的非线性特征组合，适合处理多天线、多子载波 CSI 特征之间的交互关系。

为分析最终模型实际使用的信息，本文进一步统计 700 棵树基于不纯度下降得到的特征重要性，并分别按统计量类型聚合及列出重要性最高的具体特征，如图 3.1 所示。正弦均值与余弦均值的累计贡献最高，二者合计约占总重要性的 40%，说明保留相位周期结构对分类具有明显作用；差分绝对值均值与差分标准差也占有较高权重，表明时间变化强度是姿态区分的重要依据。排名靠前的具体特征主要集中在若干子载波的 RX2/RX1 相位比链路。需要指出的是，该重要性反映模型内部的相对分裂贡献，不表示特征与姿态之间存在直接因果关系。




图 3.1 ExtraTrees 模型的特征重要性分析

3.5 检测结果输出

检测阶段对待检测 CSI 文件执行与训练阶段相同的数据处理流程。系统解析复数 CSI，计算接收天线相位比并进行时间相位展开，随后生成滑动窗口并聚合为 1620 维文件级统计特征。训练完成的 ExtraTrees 模型根据该特征向量输出三类姿态的预测结果。

该流程实现了从 WiFi CSI 原始文件到脊柱姿态类别的完整检测。由于检测过程不依赖摄像头图像或可穿戴设备，系统具有非接触、低侵入和隐私友好的特点，适用于室内场景下的人体姿态感知与脊柱健康辅助检测研究。

4 实验设计与结果分析

4.1 实验目标

实验部分围绕基于 WiFi CSI 的脊柱姿态检测方法展开，验证接收天线相位比、文件级统计特征和 ExtraTrees 分类器在三类姿态识别任务中的有效性。实验目标包括：检验 CSI 相位比特征是否能够反映不同脊柱姿态差异；比较 TCN、SVM、Random Forest 和 ExtraTrees 等模型的分类效果；分析最终模型在测试集上的准确率、精确率、召回率、F1 值和混淆矩阵表现。

4.2 数据集与划分方式

实验数据集共包含 750 个 CSI 原始文件，类别包括 kyphosis、normal 和 scoliosis，分别对应脊柱后凸相关姿态、正常姿态和脊柱侧弯相关姿态。三类样本数量均为 250 个，数据来自 5 位受试者。

图 4.1 按受试者与姿态类别展示了原始文件构成。每位受试者在三种姿态下均采集 50 个文件，因而类别与受试者维度均保持平衡，可减少由样本数量差异造成的评价偏差。




图 4.1 不同受试者与姿态类别的 CSI 文件数量

数据集采用固定随机种子 42 在原始文件级别进行划分。训练集包含 524 个文件，占 69.9%；验证集包含 113 个文件，占 15.1%；测试集包含 113 个文件，占 15.1%。划分发生在滑动窗口生成之前，因此同一原始文件产生的重叠窗口不会同时出现在训练集和测

试集中。

表 4.1 数据集划分情况

数据集	文件数	比例	用途
训练集	524	69.9%	模型参数学习
验证集	113	15.1%	模型选择与配置比较
测试集	113	15.1%	最终性能评估

各子集内部的类别数量如图 4.2 所示。训练、验证和测试子集均近似保持三类均衡，其中测试集三类文件数分别为 37、38 和 38。




图 4.2 训练集、验证集与测试集的分类分布

4.3 评价指标

为了全面评价模型分类效果，实验采用准确率、精确率、召回率和 F1 值作为主要指标。准确率表示预测正确的样本占总样本的比例：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}. \quad (4.1)$$

精确率表示被预测为某一类别的样本中真实属于该类别的比例：

$$Precision = \frac{TP}{TP + FP}. \quad (4.2)$$

召回率表示真实属于某一类别的样本中被正确识别的比例：

$$Recall = \frac{TP}{TP + FN}. \quad (4.3)$$

F1 值综合衡量精确率和召回率：

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}. \quad (4.4)$$

此外，实验使用混淆矩阵分析不同姿态类别之间的误分情况。混淆矩阵能够直观展示每个真实类别被预测为各类别的数量，有助于观察模型在哪些类别之间更容易混淆。

4.4 模型对比实验

为确定最终分类模型，本文比较了 TCN、RBF SVM、Random Forest 和 ExtraTrees 四种方案。TCN 为早期窗口级深度学习基线，输入为 512 帧 CSI 窗口；SVM、Random Forest 和 ExtraTrees 均使用文件级相位比统计特征。模型对比结果如表 4.2 所示。

表 4.2 不同模型实验结果对比

模型	输入单位	验证准确率	测试准确率	测试宏平均 F1
TCN	512 帧窗口	56.12%	50.30%	50.16%
RBF SVM	文件统计特征	约 92.04%	约 89.38%	—
Random Forest	文件统计特征	约 96.46%	约 90.27%	—
ExtraTrees	文件统计特征	95.58%	92.04%	92.08%

图 4.3 对表 4.2 中的验证和测试准确率作了直观比较。采用文件级统计特征的三种传统模型均明显优于窗口级 TCN；ExtraTrees 的验证结果略低于 Random Forest，但取得最高的测试准确率，显示出更好的留出集泛化表现。

从实验结果可以看出，TCN 在当前数据规模下测试表现较低，说明仅使用窗口级深度模型难以稳定学习到可泛化的姿态差异。RBF SVM 和 Random Forest 在文件级统计特征上表现明显提升，其中 Random Forest 测试准确率已达到 90.27%。ExtraTrees 进一步取得 92.04% 的测试准确率和 92.08% 的宏平均 F1 值，因此本文选用 ExtraTrees 作为最终分类模型。




图 4.3 不同分类模型的验证集与测试集准确率对比

4.5 最终测试结果

最终 ExtraTrees 模型在 113 个测试文件上正确分类 104 个文件，测试准确率为 92.04%。各类别的精确率、召回率和 F1 值如表 4.3 所示。

表 4.3 ExtraTrees 模型测试集分类结果

类别	Precision	Recall	F1	正确数/总数
kyphosis	87.18%	91.89%	89.47%	34/37
normal	90.00%	94.74%	92.31%	36/38
scoliosis	100.00%	89.47%	94.44%	34/38
宏平均	92.39%	92.03%	92.08%	104/113

混淆矩阵的类别顺序为 kyphosis、normal、scoliosis，结果为

$$\begin{bmatrix} 34 & 3 & 0 \\ 2 & 36 & 0 \\ 3 & 1 & 34 \end{bmatrix} \quad (4.5)$$

从混淆矩阵可见，模型对 normal 类别的召回率最高，在 38 个正常姿态测试文件中




图 4.4 ExtraTrees 模型在测试集上的混淆矩阵

正确识别 36 个；对 scoliosis 类别的精确率达到 100.00%，说明测试集中没有其他类别被误判为脊柱侧弯相关姿态；kyphosis 与另外两类之间存在少量混淆，主要表现为 3 个 kyphosis 文件被预测为 normal，以及 3 个 scoliosis 文件被预测为 kyphosis。

4.6 结果分析

实验结果表明，相位比统计特征能够较好地捕捉不同脊柱姿态对 WiFi 信道造成的差异。文件级聚合将多个窗口中的局部时间变化转化为稳定统计量，使模型能够利用完整采集文件中的整体特征进行判断。相比窗口级 TCN，ExtraTrees 在当前数据规模下具有更好的稳定性和测试集表现。

ExtraTrees 的优势主要体现在三个方面。第一，树集成模型适合处理高维统计特征，不需要像神经网络一样从有限样本中重新学习大量时序表示参数。第二，ExtraTrees 的随机特征选择和随机切分阈值能够降低树之间的相关性，提高集成模型的泛化能力。第三，模型训练和推理成本较低，便于在普通 CPU 环境中完成训练、复测和部署。

当前测试结果对应文件级留出测试条件，5 位受试者均出现在训练集、验证集和测试集中。因此，该结果反映的是已登记受试者在相近采集环境下的三类姿态识别能力。后续若面向完全陌生受试者部署，可进一步扩大受试者数量，并采用按受试者分组的划分方式评估跨人泛化能力。

5 系统实现与检测流程

5.1 系统模块划分

基于 WiFi CSI 的脊柱姿态检测系统由数据读取模块、特征处理模块、文件级特征构建模块、模型训练模块和检测输出模块组成。各模块按照数据流顺序连接，形成从 CSI 原始数据到脊柱姿态类别输出的完整处理流程。

数据读取模块负责解析 CSI 原始文件，提取时间帧、子载波、接收天线和发射天线信息；特征处理模块负责计算接收天线相位比并进行时间相位展开；文件级特征构建模块通过滑动窗口和统计聚合生成 1620 维特征向量；模型训练模块使用带标签文件训练 ExtraTrees 分类器；检测输出模块根据训练完成的模型输出最终姿态类别。

5.2 系统功能设计

系统采用分层方式组织数据处理与分类功能。数据层负责读取原始 CSI 并形成统一的复数矩阵表示；特征层完成接收天线相位比计算、时间相位展开、窗口组织和文件级统计聚合；模型层负责 ExtraTrees 分类器的训练、保存与加载；应用层接收待检测样本并输出姿态类别。各层之间通过固定维度的数据表示连接，使训练阶段和检测阶段能够复用同一套特征处理流程。

这种功能划分将 CSI 解析、特征变换和分类决策相互分离。一方面，单个处理环节可以独立验证，便于定位数据解析或特征维度错误；另一方面，当采集设备或分类模型发生变化时，可以在保持其他环节不变的情况下替换对应模块，从而提高系统的可维护性和扩展性。

5.3 训练流程

训练阶段首先读取带标签的 CSI 文件，并按照固定随机种子在文件级划分训练集、验证集和测试集。随后，系统对每个文件执行 CSI 解析、接收天线相位比计算、相位展开、滑动窗口生成和文件级统计特征聚合，得到用于分类的 1620 维特征向量。

在模型训练阶段，ExtraTrees 分类器使用训练集文件特征学习分类规则，并通过验证集比较不同配置的表现。最终模型使用 700 棵极端随机树、类别平衡权重、平方根特征采样和固定随机种子。训练完成后，系统保存模型文件和实验指标，便于后续复测和部署。

训练完成后，系统保存分类模型，并记录数据划分、训练配置和评价指标。模型参数与实验元数据分别保存，使后续复测能够恢复与训练阶段一致的数据处理配置，同时

避免测试集信息参与模型选择。

5.4 检测流程

检测阶段对新的 CSI 文件执行与训练阶段一致的数据处理流程。系统首先解析复数 CSI，然后以第 0 根接收天线为参考计算相位比，并沿时间维度展开相位；之后生成长度为 512、步长为 256 的滑动窗口，并将该文件的全部窗口聚合为 1620 维统计特征；最后加载序列化后的 ExtraTrees 模型，输出三类姿态之一。

检测流程可表示为

$$X_{\text{raw}} \rightarrow X_{\text{csi}} \rightarrow X_{\text{ratio}} \rightarrow X_{\text{stat}} \rightarrow \hat{y}. \quad (5.1)$$

其中 X_{ratio} 表示相位比序列， X_{stat} 表示文件级统计特征， $\hat{y}$ 表示最终检测类别。

5.5 复现性验证

模型训练完成后，本文在独立运行环境中重新加载所保存的模型，并按照训练时记录的数据划分和特征配置对测试集进行复测。复测得到 92.04% 的测试准确率和 92.08% 的宏平均 F1 值，分类报告与混淆矩阵均与原始实验结果一致。这表明模型序列化过程未改变分类行为，训练与检测阶段的数据处理流程也保持一致。

5.6 应用特点

该系统不依赖摄像头图像和可穿戴设备，能够在室内 WiFi 环境下进行非接触式姿态感知。系统通过 CSI 相位比特特征捕获人体姿态对无线信道的影响，并利用文件级统计特征和 ExtraTrees 集成分类器完成三类姿态检测，具有隐私友好、部署成本低和计算开销较小等特点。

结 论

本文围绕基于 WiFi CSI 的脊柱姿态检测问题，研究了一种非接触式三分类识别方法。该方法利用人体姿态变化对无线信道的扰动作用，将脊柱姿态检测建模为正常姿态、脊柱后凸相关姿态和脊柱侧弯相关姿态的分类任务，并通过接收天线相位比、文件级统计特征和 ExtraTrees 集成分类器实现姿态识别。

本文首先分析了 WiFi CSI 在人体姿态感知中的作用，说明 CSI 幅度和相位能够反映无线传播路径变化。针对原始相位容易受到硬件偏移和公共相位误差影响的问题，本文采用接收天线相位比构造相对相位特征，并沿时间维度进行相位展开。随后，本文使用滑动窗口组织连续 CSI 序列，并将每个原始文件聚合为 1620 维统计特征。最终，本文采用 ExtraTrees 分类器学习统计特征与脊柱姿态类别之间的映射关系。

实验使用 750 个 CSI 原始文件，三类姿态各 250 个样本，并在文件级划分训练集、验证集和测试集。最终模型在 113 个测试文件上取得 92.04% 的准确率和 92.08% 的宏平均 F1 值。其中，正常姿态 F1 值为 92.31%，脊柱后凸相关姿态 F1 值为 89.47%，脊柱侧弯相关姿态 F1 值为 94.44%。实验结果表明，基于相位比统计特征和 ExtraTrees 的方法能够有效区分三类脊柱姿态。

本文建立了从 CSI 数据读取、特征处理、模型训练到检测输出的完整技术流程，为基于 WiFi 信号的脊柱姿态辅助检测提供了一种可行方案。该方法具有非接触、低侵入和隐私友好的特点，适用于室内场景下的人体姿态感知研究。后续工作可从受试者规模扩展、跨人泛化评估、幅度与相位融合、环境增强和实时检测流程设计等方面继续展开，以进一步提升系统在实际应用中的稳定性和适用范围。

参 考 文 献

参考文献

- [1] Halperin D, Hu W, Sheth A, et al. Tool release: gathering 802.11n traces with channel state information[J]. ACM SIGCOMM Computer Communication Review, 2011, 41(1): 53.
- [2] Li X, Zhang D, Lv Q, et al. IndoTrack: Device-free indoor human tracking with commodity Wi-Fi[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2017, 1(3): 1-22.
- [3] Ma Y, Zhou G, Wang S, et al. SignFi: Sign language recognition using WiFi[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2018, 2(1): 1-21.
- [4] Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.
- [5] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [6] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine Learning, 2006, 63(1): 3-42.
- [7] Bai S, Kolter J Z, Koltun V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J]. arXiv preprint arXiv:1803.01271, 2018.
- [8] Forbes G. CSIKit: Python CSI processing and visualisation toolkit[EB/OL]. 2021. <https://github.com/Gi-z/CSIKit>.